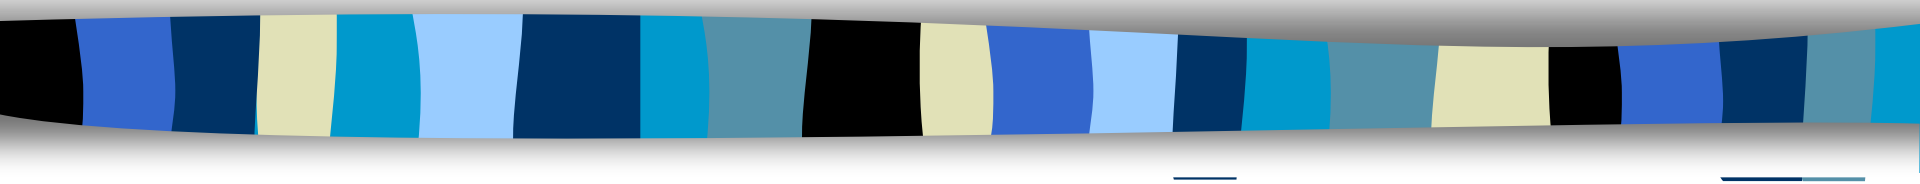
Business Forecasting Methods



รศ. ดร. อนุกัลยณ์ จีระลักษณกุล

Forecast

- ทำไมต้อง Forecast?
  - เพื่อใช้ในกระบวนการวางแผน
  - บริษัทวางแผนเพื่อใช้ในการกำหนด Action เพื่อไม่ให้เหตุการณ์หรือการตัดสินใจต่างๆ เกิดขึ้นโดยไม่มีการเตรียมการณ์ไว้ก่อน

Business Examples : Harrah

- ลูกค้าโทรเข้ามาเพื่อจองห้องพัก โรงแรมควรจะตอบรับหรือปฏิเสธ?
  - Capacity?
  - Customer behavior in gambling?
  - Opportunity cost?

Business Examples : Harrah

- **Revenue Management (RM)**
  - Harrah สามารถเก็บข้อมูลเชิงพฤติกรรมของลูกค้าได้อย่างละเอียด
  - ลูกค้าแต่ละคนมี Willingness to Pay สำหรับห้องแบบเดียวกันที่แตกต่างกัน
  - โรงแรมสามารถที่จะกันห้องและรอลูกค้าให้จองนาทีสุดท้ายได้

Business Examples : Harrah

- RM System
  - Data collection for each segment
  - Forecasting demand for each segment
  - Optimization model to decide which reservation to accept
  - Customer relationship management model
- **Result:** **Nearly full occupancy and 60% profit margin**

ตัวอย่างอื่นของ Business Forecasting

- ร้าน Fast-food วางแผนในการจัดจำนวนพนักงานในการให้บริการในแต่ละช่วงเวลาของวัน
- บริษัทวางแผนในการสั่งหรือผลิตสินค้าเพื่อขายให้กับลูกค้า
- องค์กรที่ลงทุนในสินทรัพย์ต่างๆ พยายามที่จะพยากรณ์การเคลื่อนไหวของราคาของสินทรัพย์และอัตราดอกเบี้ย
- ภาครัฐพยายามที่จะพยากรณ์การเคลื่อนไหวของตัวแปรทางเศรษฐศาสตร์มหภาค เช่น อัตราเงินเฟ้อ ในการกำหนดนโยบายทางเศรษฐกิจ

วิธีการพยากรณ์ (Forecasting Methods)

วิธีการพยากรณ์โดยทั่วไปแล้วสามารถแบ่งออกได้เป็น 3 กลุ่ม คือ

1. กลุ่มวิธีที่ใช้วิจารณญาณ (Judgmental methods)
2. กลุ่มวิธีของการใช้อนุกรมเวลา (Time series methods)
3. กลุ่มวิธีของการใช้เหตุและผล (Casual methods) หรือ Econometric methods

วิธีการเชิงปริมาณ (Quantitative Methods)

จุดแข็ง	จุดอ่อน
• มีความเป็นกลาง (Objective) และความสม่ำเสมอ • สามารถใช้ได้กับข้อมูลจำนวนมาก • สามารถใช้ได้ในกรณีที่มีจำนวนตัวแปรมากและมีความสัมพันธ์ที่ซับซ้อน	• การพยากรณ์ดีเท่ากับ model ที่ใช้และข้อมูลที่มี • ตอบสนองต่อสภาพแวดล้อมที่เปลี่ยนไปได้ช้า • มีต้นทุนสูงหรือเป็นไปได้ยากที่จะรวมปัจจัยที่วัดได้ยากเข้าไปในการพยากรณ์ด้วย • จำเป็นต้องมีความเข้าใจในด้านสถิติ (ทั้งผู้พยากรณ์และผู้ใช้)

วิธีพยากรณ์แบบ Judgemental

- เป็นกระบวนการพยากรณ์ที่ตั้งอยู่บนพื้นฐานของการผสมรวม ข้อมูลสารสนเทศและความเชื่อส่วนบุคคลของคนต่างๆ เข้าด้วยกัน

ผู้เชี่ยวชาญคนเดียว (Single Expert)

- ค่าพยากรณ์มาจากผู้เชี่ยวชาญเพียงคนเดียว
- มักจะมีความโน้มเอียงหรืออคติ (Bias) หรือมักจะเป็นการคิดถึงสิ่งที่ต้องการให้เกิดขึ้น (โดยผู้พยากรณ์)
- อาจจะแยกไม่ออกหระหว่าง สิ่งที่น่าจะเกิดขึ้น (Forecast) กับสิ่งที่เราต้องการให้เกิด (Target)

ความเห็นของกลุ่มผู้เชี่ยวชาญ

- เป็นการนำความเห็นของผู้เชี่ยวชาญหรือผู้บริหารจากหลากหลายความรับผิดชอบ (เช่น การขาย การตลาด การผลิต การเงิน) มาอภิปรายร่วมกันเพื่อตกลงที่จะหาค่าพยากรณ์ที่ต้องการ

- ปัญหา Group Think

วิธี Sale Force Composite

- ใช้ Sale Force ในการพยากรณ์ในพื้นที่หรือสินค้าที่แต่ละคนรับผิดชอบหรือมีความเชี่ยวชาญ เพื่อนำมารวมเป็นการพยากรณ์ในภาพรวม
- ระวังการมองว่า Forecast เป็น Target

วิธีการเชิงคุณภาพ (Qualitative Methods)

จุดแข็ง	จุดอ่อน
• ตอบสนองต่อสภาพแวดล้อมที่เปลี่ยนไปได้เร็วและง่าย • สามารถใช้ข้อมูลภายในเชิงลึก (Inside Information) ร่วมในการพยากรณ์ได้ • ใช้ได้สำหรับเหตุการณ์ที่ไม่ได้เกิดขึ้นบ่อย	• มี Bias • อาจจะขาดความสม่ำเสมอ • การพยากรณ์อาจจะเป็นการคิดถึงสิ่งที่ผู้พยากรณ์ต้องการให้เกิด • ใช้เวลามากและอาจจะมีต้นทุนสูง

Quantitative VS Qualitative Methods

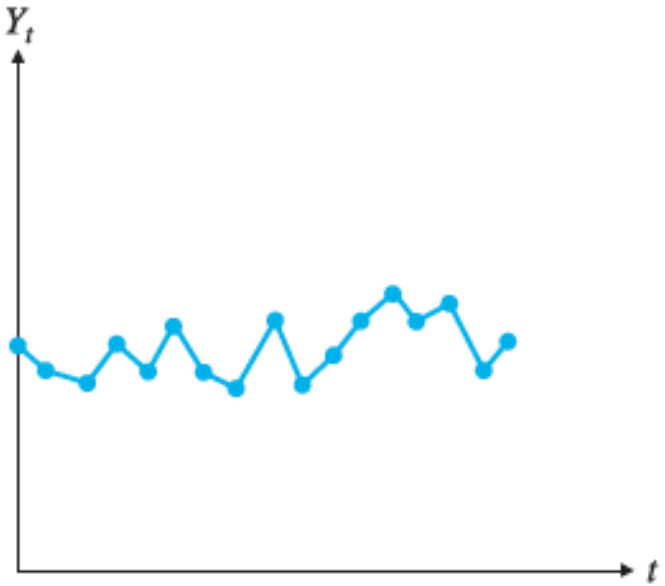
- ข้อมูลเชิงปริมาณมีหรือไม่?
- ความสำคัญของการนำค่าพยากรณ์ไปใช้งาน?
- มีจำนวนค่าที่ต้องการพยากรณ์มากเท่าไหร่?
- มีข้อมูลอะไรที่ไม่สามารถรวมเข้าไปในวิธีการพยากรณ์เชิงปริมาณหรือไม่?

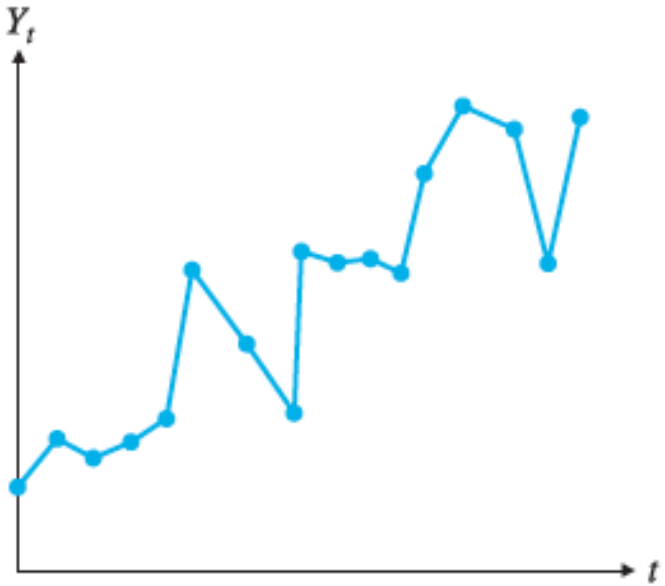
Time Series Methods

- Quantitative method
- Use past data of a time series
- Search for patterns in historical data
- Extrapolate these patterns into the future

Time Series Methods

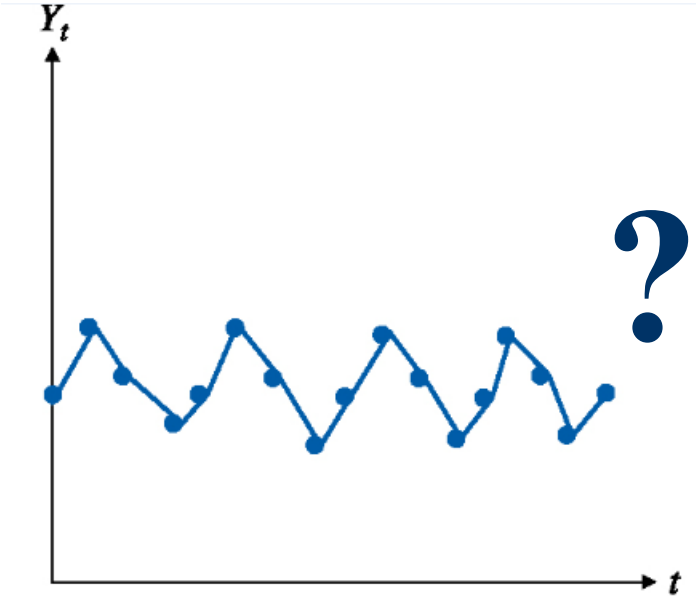
- แยก pattern ที่เป็น Noise / Random pattern กับ Pattern ที่มีรูปแบบออกจากกันให้ได้

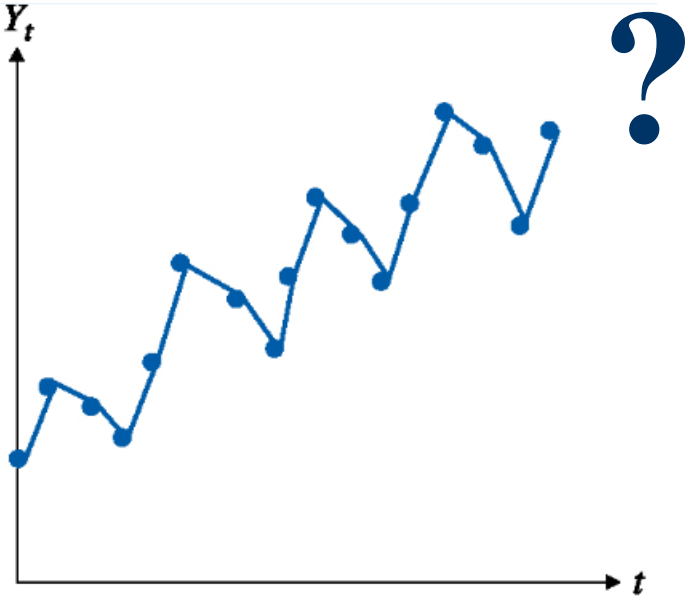




Time Series Methods

- อาจจะไม่มีเหตุผลที่ Pattern จากอดีตจะดำเนินต่อไปในอนาคต





Empirical Evidence

- Complex forecasting methods ไม่ได้ทำนายได้ดีกว่าวิธีการแบบพื้นฐานเสมอไป
- การใช้การเฉลี่ยนแบบถ่วงน้ำหนักของสองหรือสามวิธีร่วมกัน (Weighted Average of Forecasts)

Econometric Methods

* ตัวอย่างของสมการที่ใช้ในการพยากรณ์

$$Y_t = \alpha + \beta_1 X_{1t} + \beta_2 X_{2t}$$

Y_t คือ ตัวแปรตอบสนองที่เราต้องการพยากรณ์ ณ ช่วงเวลา t

X_{1t}, X_{2t} คือ ตัวแปรอธิบายที่เรานำมาอธิบายตัวแปรตอบสนอง ณ ช่วงเวลาเดียวกัน

Econometric Methods

$$Y_t = Y_{t-1} + \alpha + \beta_1 X_{1,t} + \beta_2 X_{2,t}$$

Sale month t

Sale month t-1

Auto-correlation

Econometric Methods

$$Y_t = Y_{t-1} + \alpha + \beta_1 X_{1,t} + \beta_2 X_{2,t} + \beta_3 X_{1,t-1} + \beta_4 X_{2,t-1}$$

Advertising month t

Competitor's Advertising month t-1

Cross-correlation

ARIMA (Box-Jenkins Models)

- Developed by Box and Jenkins (1970)
  - Autoregressive (AR) model
  - Moving Average (MA) model
  - Autoregressive Moving Average (ARMA) model
  - Autoregressive Integrated Moving Average (ARIMA) model
- Data-driven, autocorrelation functions

การวัดความคลาดเคลื่อน (Error)

การวัดความคลาดเคลื่อน (Error)

F_t คือ ค่าพยากรณ์สำหรับเวลา t

Y_t คือ ค่าที่ได้จริงจากการเก็บข้อมูลที่เวลา t

E_t คือ ความคลาดเคลื่อนของการพยากรณ์ที่เวลา t

ซึ่งสามารถคำนวณได้ดังนี้

$$E_t = Y_t - F_t$$

Error = Observed value – Fitted value

ตัวอย่าง: พยากรณ์ยอดขาย

Week t	Forecast (Ft)	Actual (Yt)	Error (Et)
1	25	22	
2	22	28	
3	26	27	

การวัดความคลาดเคลื่อน (Error)

- Mean Absolute Error (MAE)

$$MAE = \frac{1}{N}\sum_{t=1}^{N}|E_t|$$

การวัดความคลาดเคลื่อน (Error)

- Root Mean Square Error (RMSE)

$$RMSE = \sqrt{\frac{1}{N}\sum_{t=1}^{N} E_t^2}$$

การวัดความคลาดเคลื่อน (Error)

- Mean Absolute Percentage Error (MAPE)

$$MAPE = \frac{1}{N}\sum_{t=1}^{N}\left|\frac{E_t}{Y_t}\right|$$

การวัดความคลาดเคลื่อน (Error)

โดยทั่วไปแล้ว ความคลาดเคลื่อนทั้งสาม 3 รูปแบบ คือ

$$MAE = \frac{1}{N}\sum_{t=1}^{N}|E_t|$$

$$RMSE = \sqrt{\frac{1}{N}\sum_{t=1}^{N}E_t^2}$$

$$MAPE = \frac{1}{N}\sum_{t=1}^{N}\left|\frac{E_t}{Y_t}\right|$$

มักจะให้ผลในทิศทางเดียวกันเสมอ

องค์ประกอบของ

Time Series Data

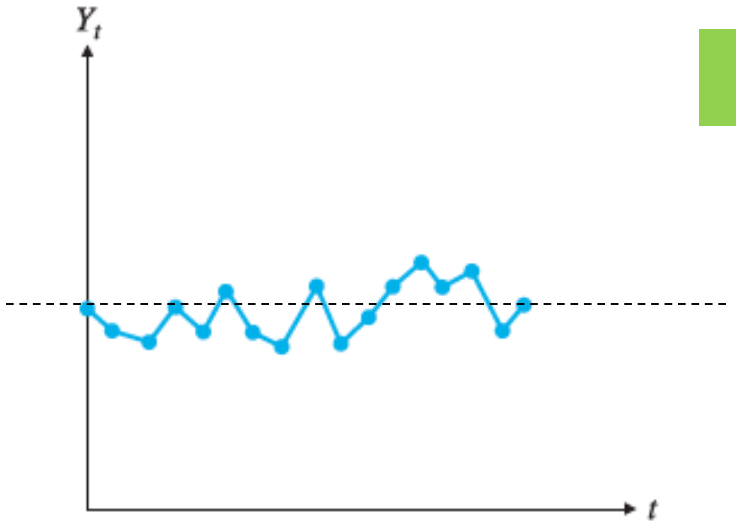
องค์ประกอบของ *Time Series Data*

องค์ประกอบของ Time series data โดยทั่วไปแล้วสามารถแบ่งออกได้เป็น 4 องค์ประกอบหลัก คือ

- Noise หรือ Randomness
- แนวโน้ม (Trend)
- ฤดูกาล (Seasonality)
- วัฏจักร (Cycle)

องค์ประกอบของ *Time Series Data*

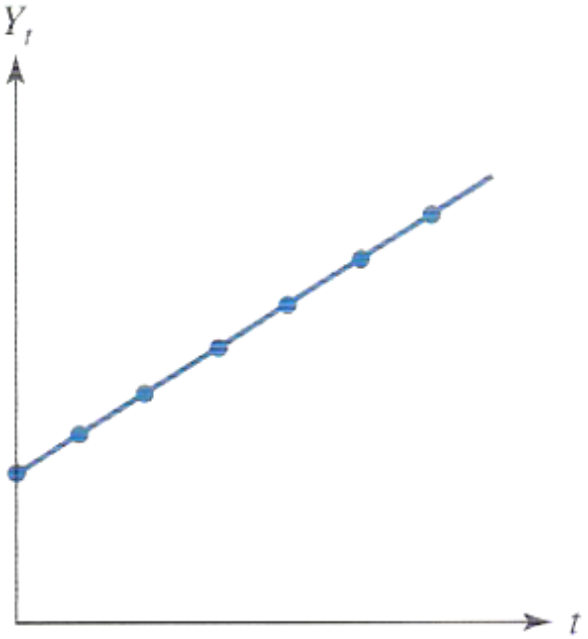
Noise หรือ Randomness – ค่าของตัวแปรที่ไม่มีรูปแบบใดๆ เลย ทำให้ไม่สามารถคาดการณ์ค่าได้ในอนาคต



Noise Component Only

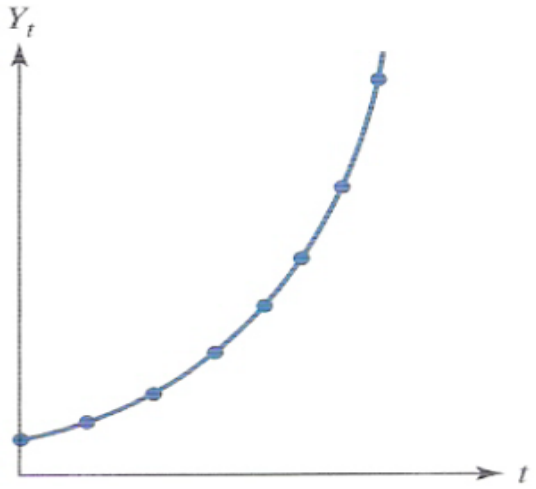
องค์ประกอบของ *Time Series Data*

แนวโน้ม (Trend) – ค่าของตัวแปรมีค่าเพิ่มขึ้นหรือลดลงอย่างต่อเนื่องและเป็นระบบ

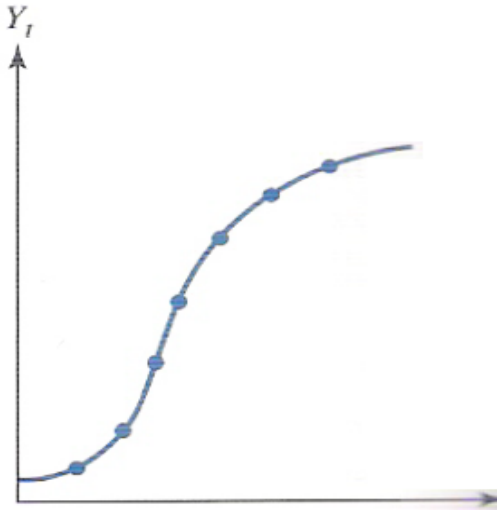


Linear trend

องค์ประกอบของ *Time Series Data*



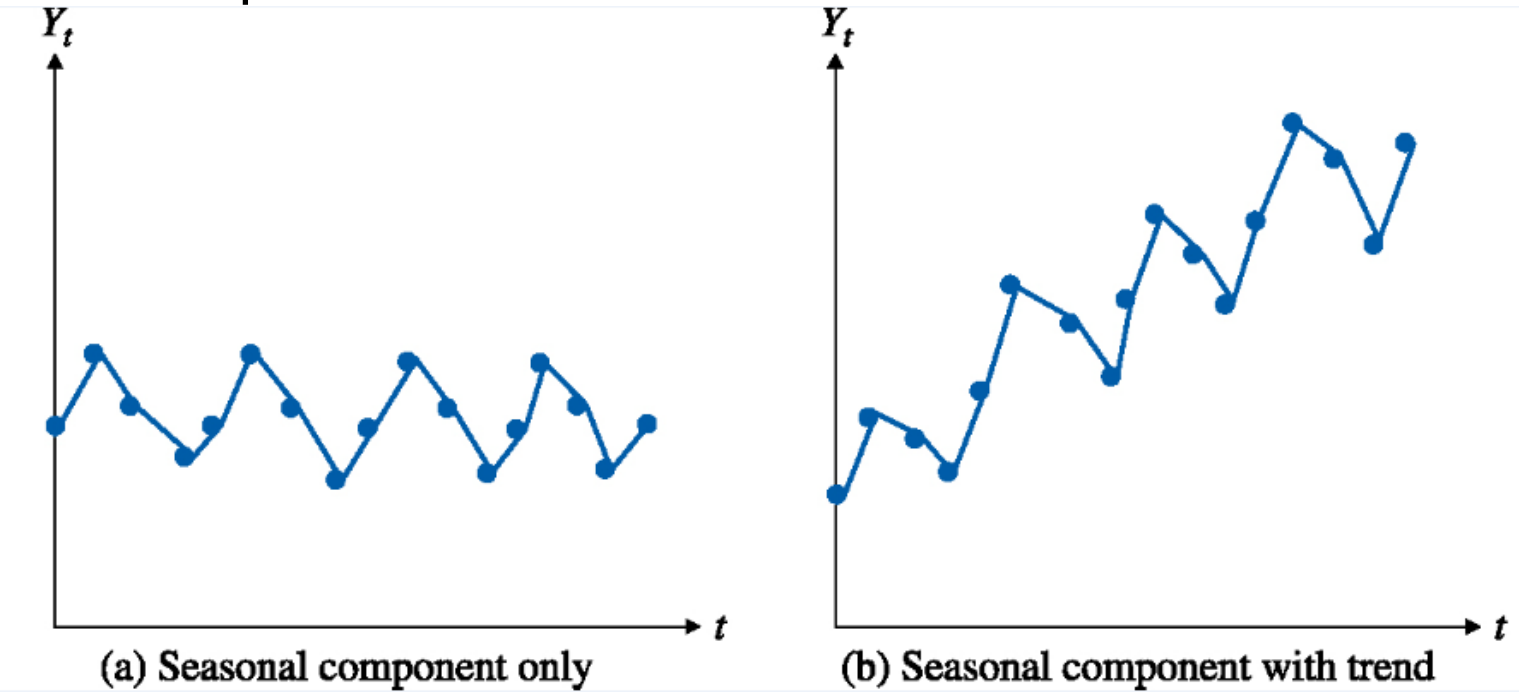
Exponential trend



S- shaped trend

องค์ประกอบของ *Time Series Data*

ฤดูกาล (Seasonality) – ค่าของตัวแปรมีรูปแบบที่ซ้ำกันเป็นรอบในช่วงเวลาที่เท่ากัน และมีรูปแบบที่ซ้ำกันแบบนี้ไปเรื่อยๆ

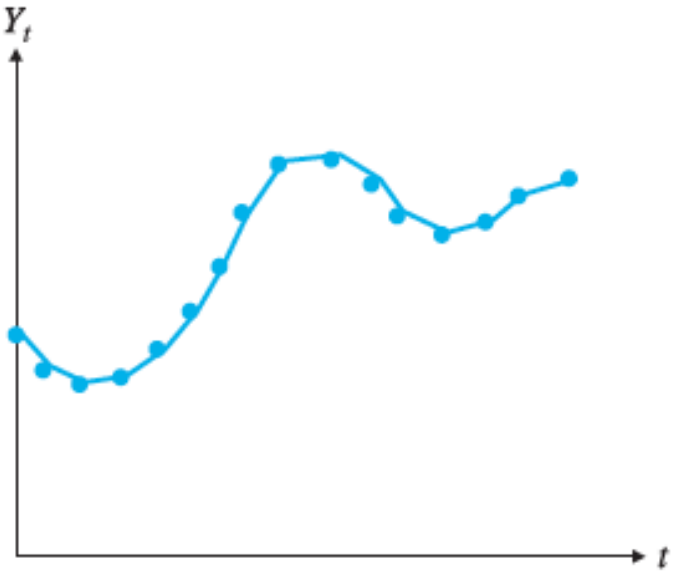


(a) Seasonal component only

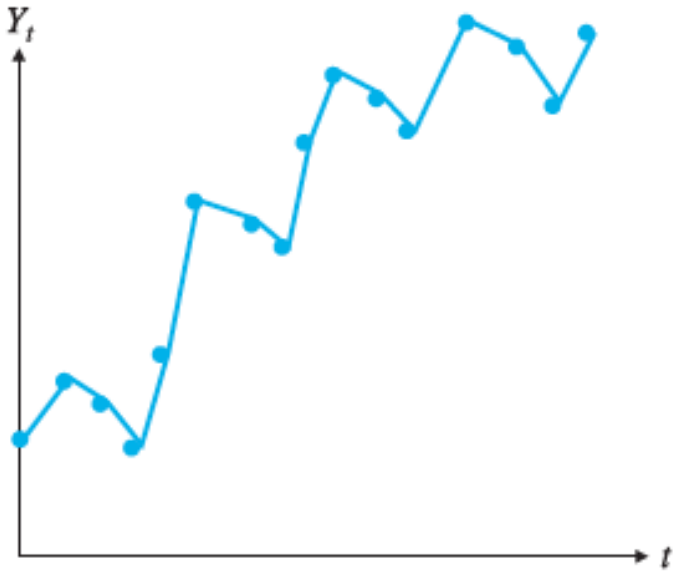
(b) Seasonal component with trend

องค์ประกอบของ *Time Series Data*

วัฏจักร (Cycle) – ค่าของตัวแปรมีการเปลี่ยนแปลงเป็นแบบวัฏจักร



(a) Cyclic component only



(b) Cyclic component with seasonality and trend

Runs Test

Runs Test

* Runs test คือ การทดสอบสมมติฐานว่า Time Series เป็น Noise หรือ Random pattern หรือไม่

* Null hypothesis : Time Series เป็น Random Pattern

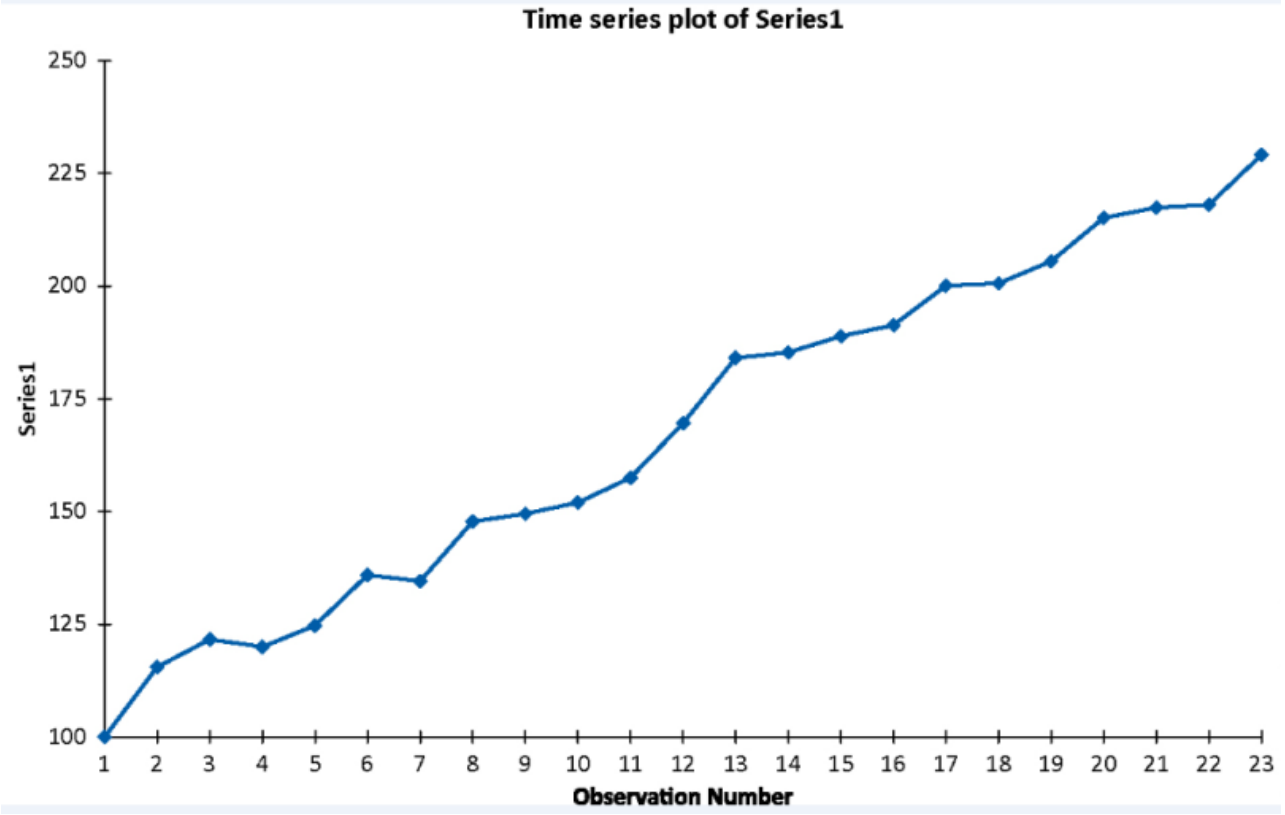
* เมื่อทดสอบแล้วถ้ามีจำนวน Runs ที่มากเกินไปหรือน้อยเกินไป เราจะปฏิเสธ Null hypothesis และยอมรับว่า Time Series ไม่เป็น Random pattern

ตัวอย่างของการนับจำนวน Run

- สมมติว่าเราเก็บข้อมูลได้ดังนี้ 1, 5, 3, -3, -2, -4, -1, 3, 2
- ถ้าเราตั้งระดับฐาน (Baseline) ไว้ที่ค่าศูนย์ เราก็จะนับได้ว่าข้อมูลที่เก็บมามีจำนวน Run ทั้งหมด 3 Runs คือ
  - Run 1: 1, 5, 3
  - Run 2: -3, -2, -4, -1
  - Run 3: 3, 2

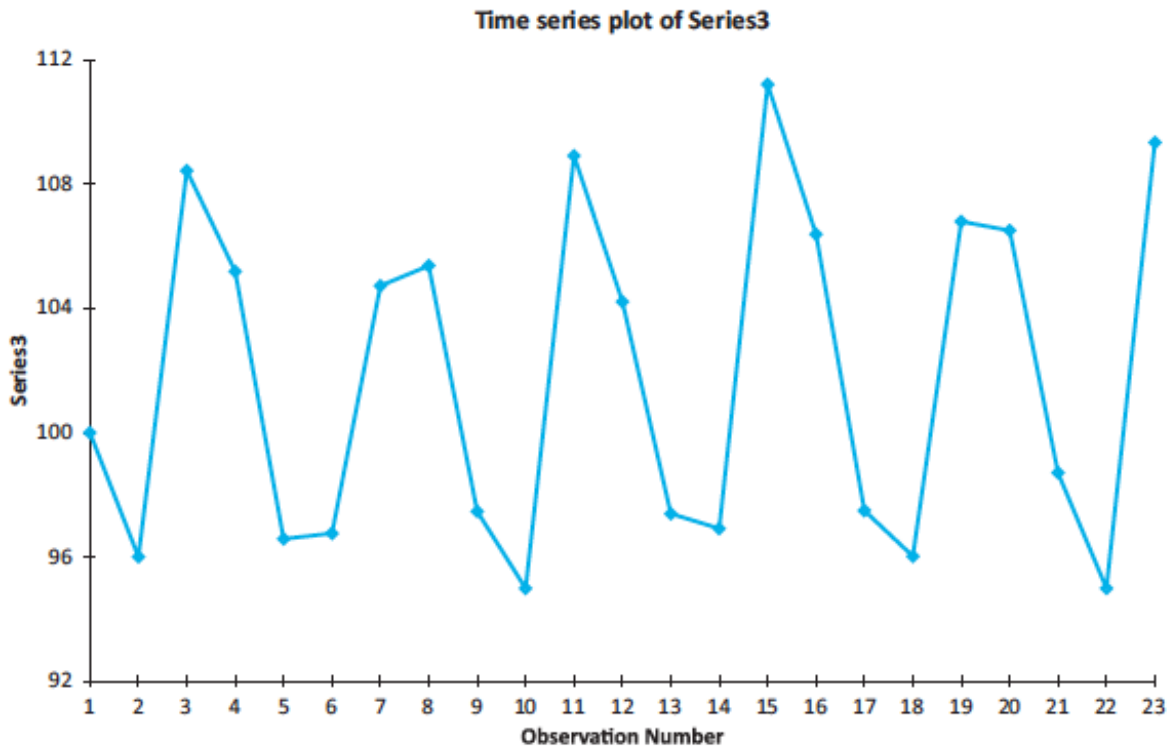
Runs Test

* ถ้าข้อมูลมีจำนวน Run ที่ค่อนข้างน้อย ข้อมูลอาจมีลักษณะของ Trend

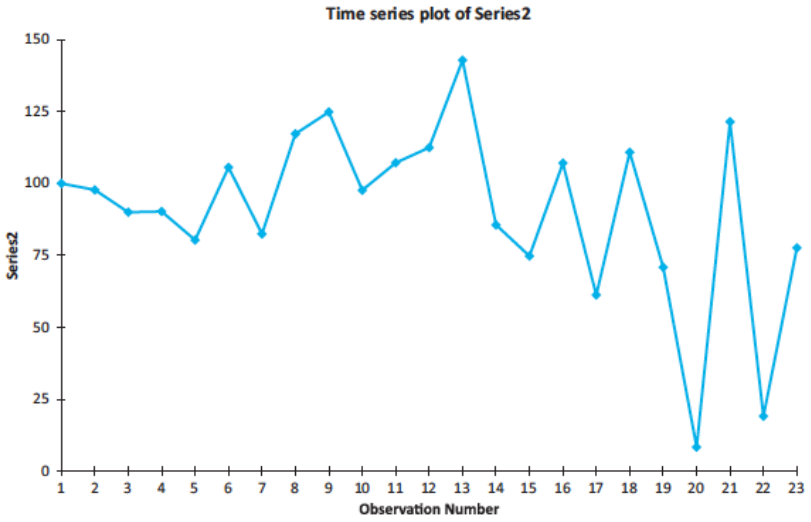


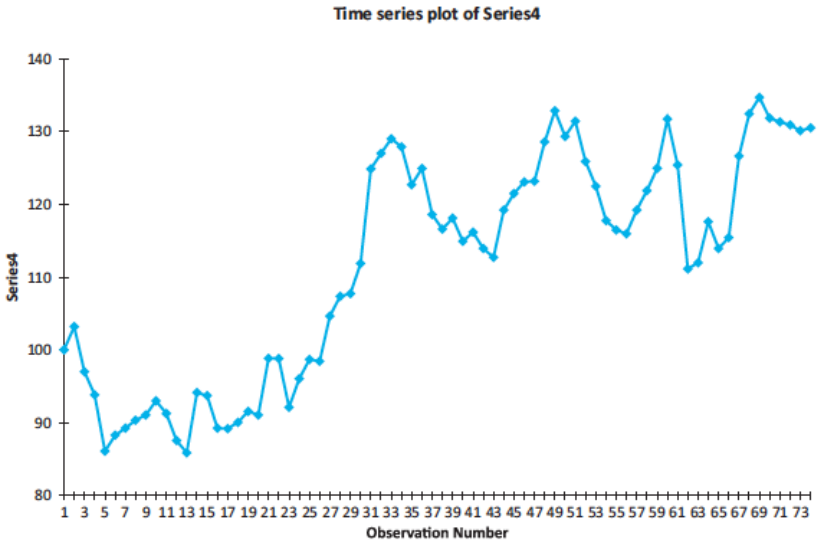
Runs Test

* ถ้าข้อมูลมีจำนวน Run ที่มากเกินไป ข้อมูลจะมีลักษณะเป็นแบบซิกแซก (Zig-zag)



Runs Test


Time series plot of Series2
Series2
Observation Number
150
125
100
75
50
25
0
1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23


Time series plot of Series4
Series4
Observation Number
140
130
120
110
100
90
80
1 3 5 7 9 11 13 15 17 19 21 23 25 27 29 31 33 35 37 39 41 43 45 47 49 51 53 55 57 59 61 63 65 67 69 71 73

Runs Test

- ทำการทดสอบ Run Test (ใน StatTools)
- อ่านค่า p-value ของการทดสอบ
  - ถ้า p-value < 0.05 สรุปว่า Time Series ไม่เป็น Random Pattern (ปฏิเสธ Null Hypotheses)
  - ถ้า p-value >= 0.05 สรุปว่า Time Series เป็น Random Pattern

(โอกาสของความผิดพลาดของการทดสอบ = 5%)

ตัวอย่าง

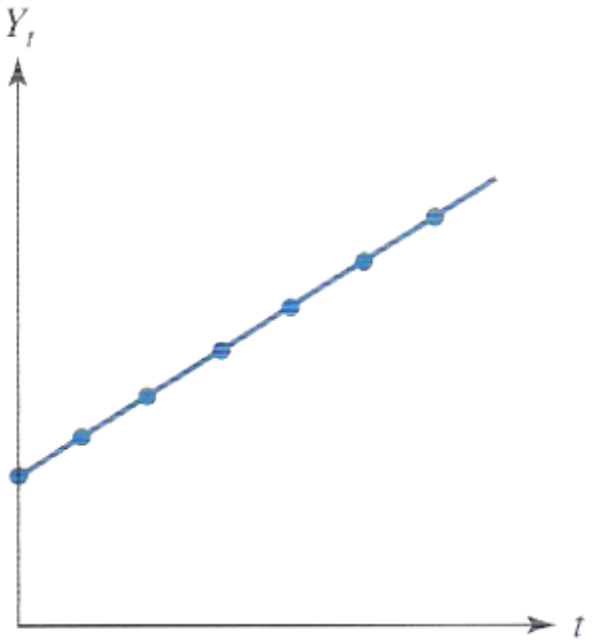
- Stereo Sale.xlsx
- โจทย์
  - 1) Data Set 12_02
  - 2) Data Set 12_03
  - 5) Data Set 12_05

Trend Model

(Regression-based)

Linear Trend

- A **linear trend** means that the time series variable changes by a constant *amount* each time period.

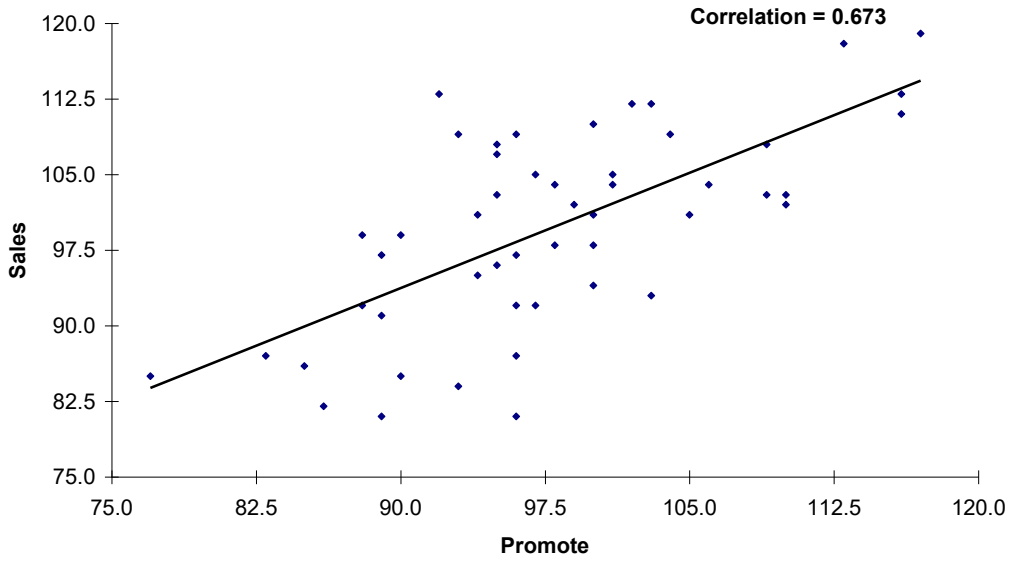


$$Y_t = a + bt + e_t$$

- b = slope – change between time period
  - If *b* is positive, the trend is upward.
  - If *b* is negative, the trend is downward.
- a = intercept – represent the expected value of the series at time $t = 0$.

- A graph of the time series indicates whether a linear trend is likely to provide a good fit.

Linear Regression



$$Y\ (Sales) = a + b\ X\ (Promote)$$

ใช้วิธี Least Square Methods ในการประมาณค่าสัมประสิทธิ์ a และ b ที่ทำให้ Residual หรือ Error มีค่าน้อยที่สุด

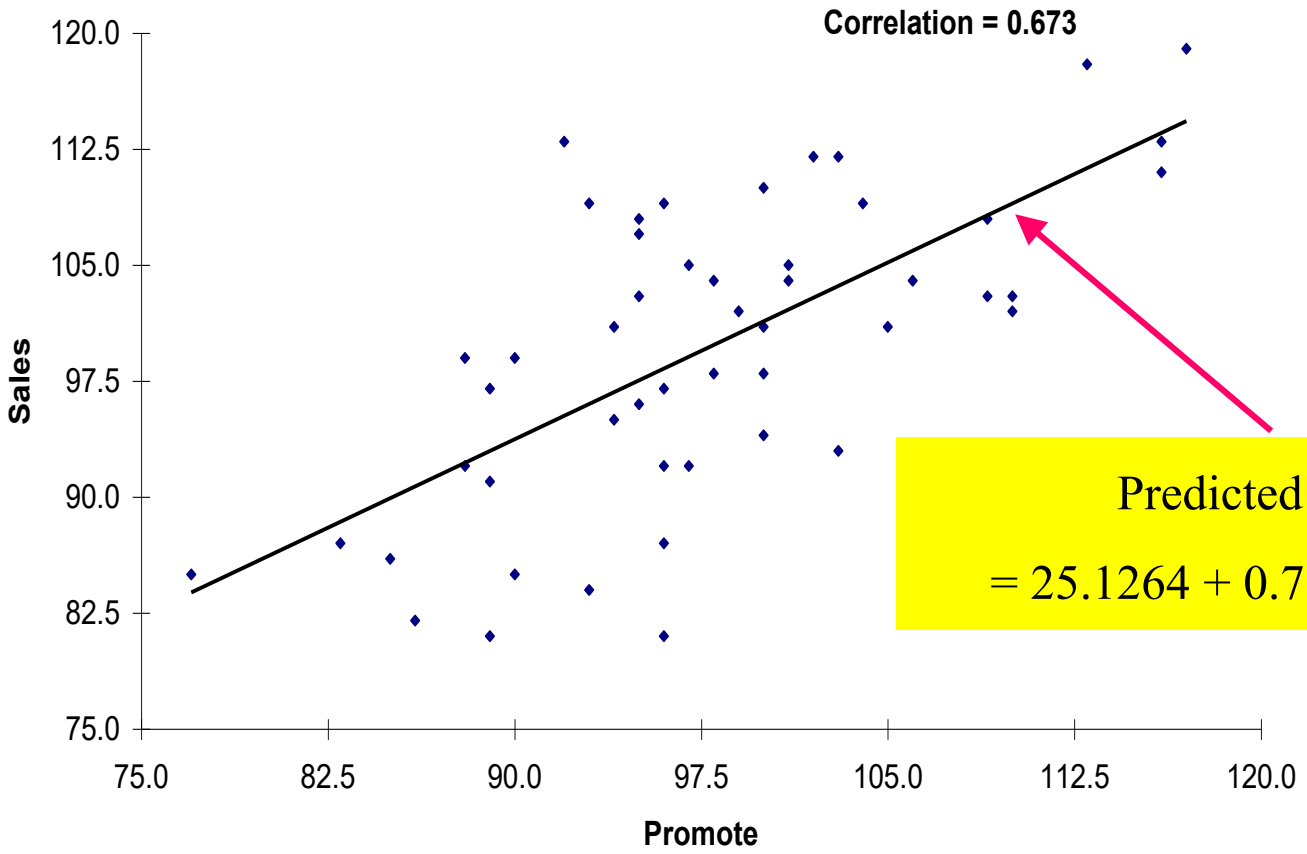
$$Residual = Observed\ value - Fitted\ value$$

R^2 คือ สัดส่วนของความแปรปรวนของ Response variable ที่สามารถอธิบายได้ด้วย Regression line

P-value ของ ANOVA และของค่าสัมประสิทธิ์แต่ละตัวบอกถึงนัยสำคัญทางสถิติของตัวแปรแต่ละตัวว่ามีผลกระทบต่อตัวแปร Y

Linear Regression

$$Y\ (Sales) = a + b\ X\ (Promote)$$

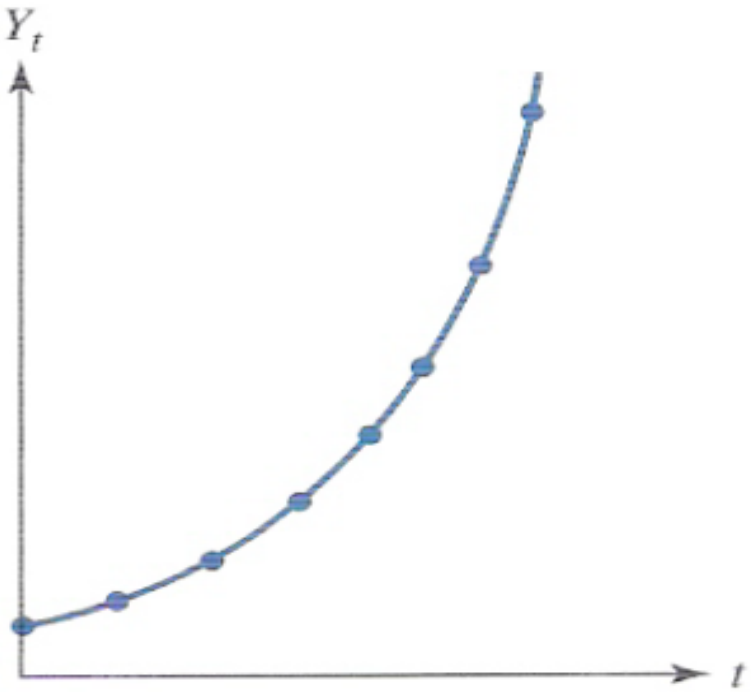


ความหมายของ a และ b?

ตัวอย่างการ Forecast Linear Trend

- US Population
- โจทย์: ให้ทำพยากรณ์โดยใช้ Linear Trend
  - 9) Data Set 12_01

Exponential Trend



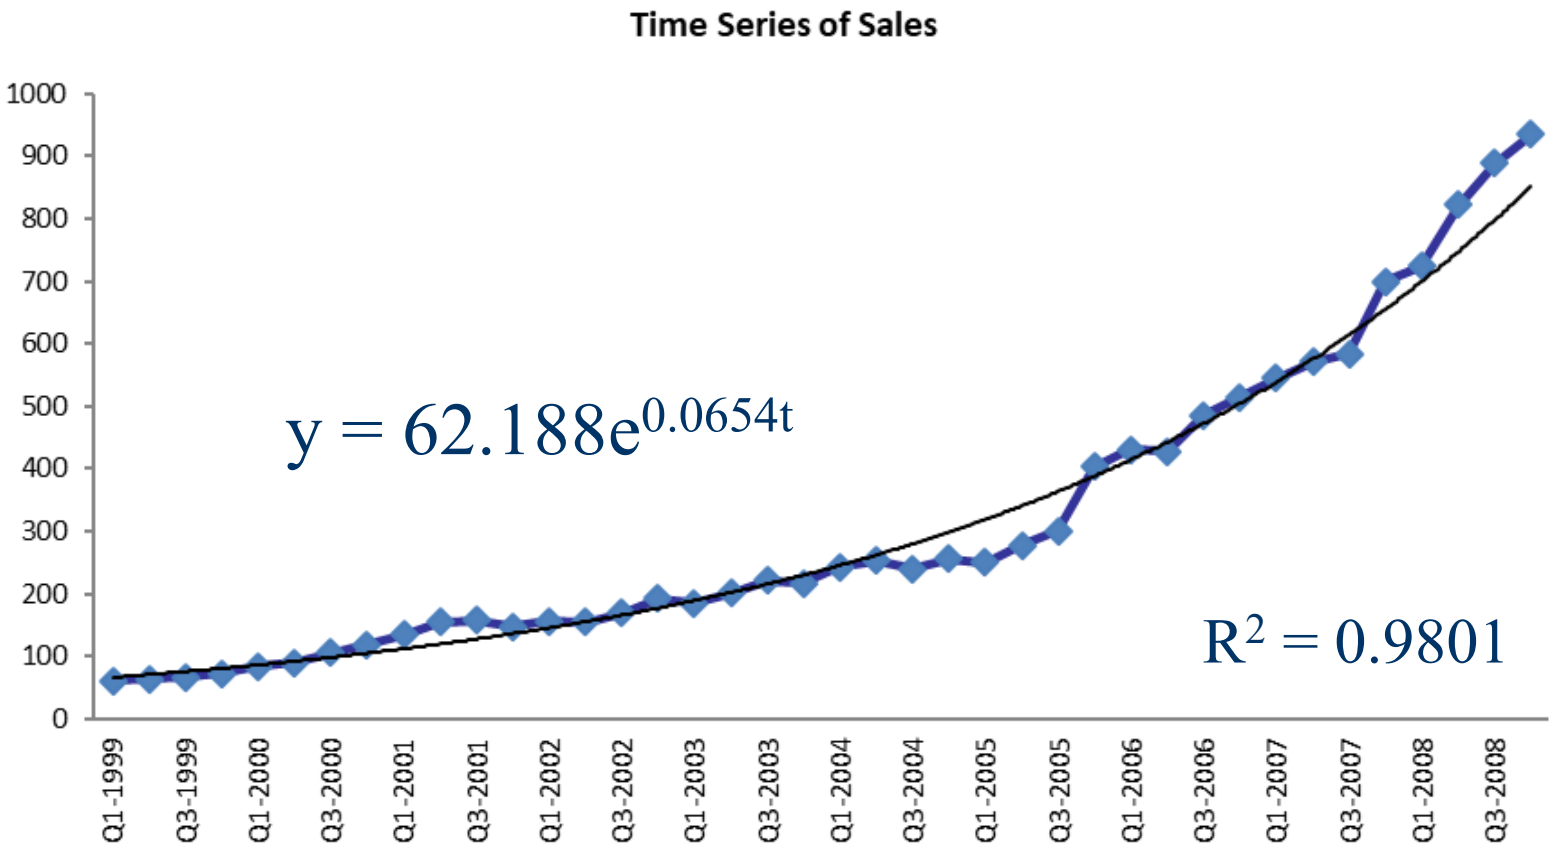
- An *exponential* trend is appropriate when the time series changes by a constant *percentage* each period.
- The appropriate regression equation contains a *multiplicative* error term u_t

$$Y_t = ce^{bt}u_t$$

- If a time series exhibits an exponential trend, then a plot of its logarithm should be approximately linear.

$$\ln(Y_t) = a + bt + e_t$$

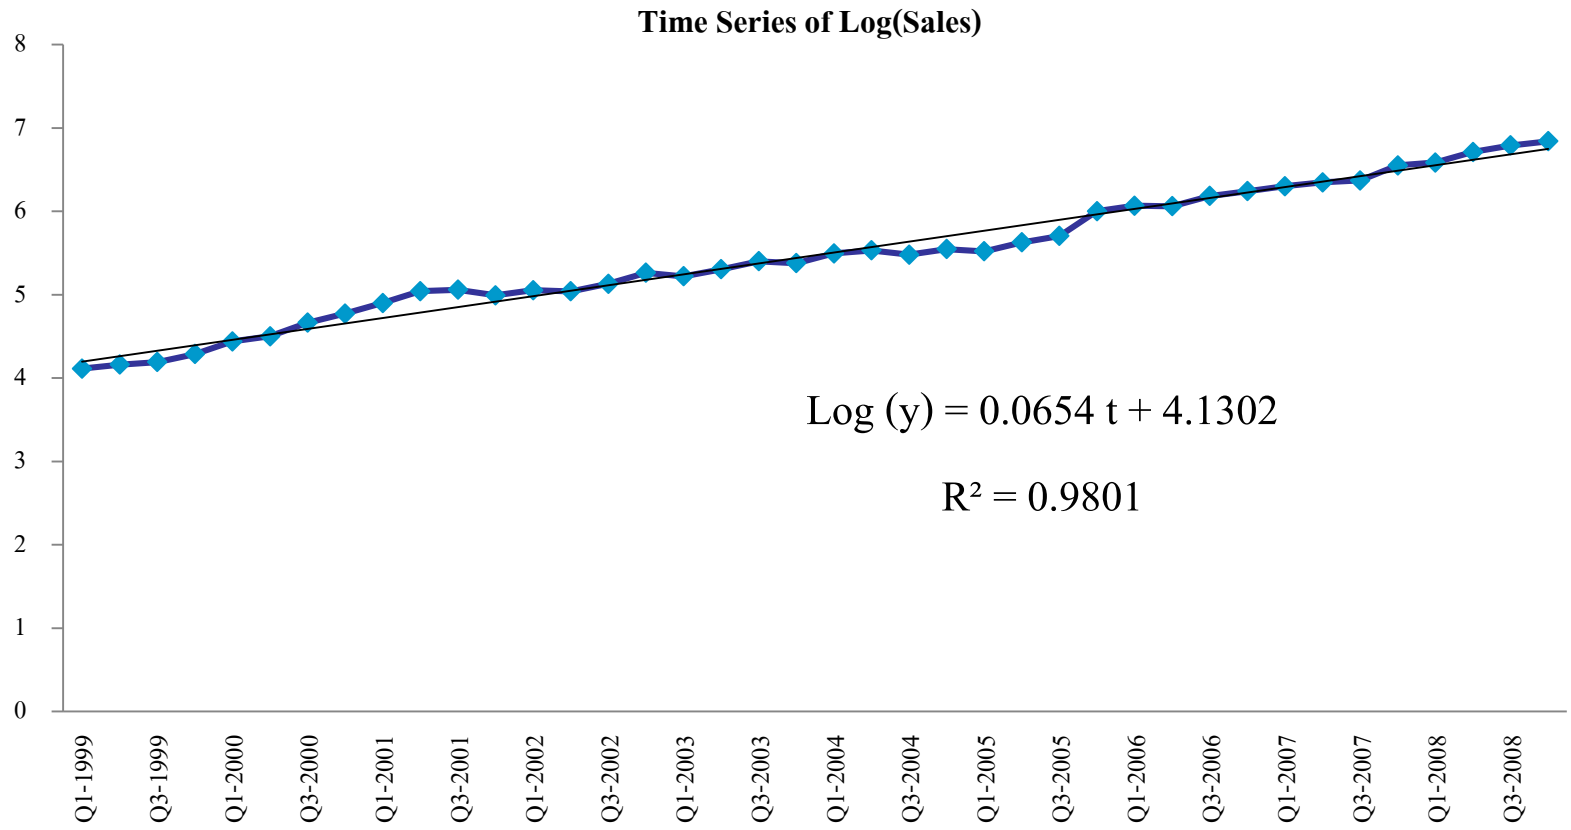
โดยที่ $a = \ln(c)$ และ $e_t = \ln(u_t)$


Time Series of Sales
1000
900
800
700
600
500
400
300
200
100
0
Q1-1999
Q3-1999
Q1-2000
Q3-2000
Q1-2001
Q3-2001
Q1-2002
Q3-2002
Q1-2003
Q3-2003
Q1-2004
Q3-2004
Q1-2005
Q3-2005
Q1-2006
Q3-2006
Q1-2007
Q3-2007
Q1-2008
Q3-2008
y = 62.188e^0.0654t
R^2 = 0.9801

การแปลง Data โดยใช้ LN( ) ใน Excel

Quarter	Sales	Log (Sales)
Q1-1999	61.14	4.11
Q2-1999	64.07	4.16
Q3-1999	66.18	4.19
Q4-1999	72.76	4.29

=LN(61.14)



แปลงค่ากลับเป็น **Y (Sales)** โดยใช้ **=EXP(4.1302+0.0654t)**

ความหมายของ **b = %** ของการเปลี่ยนแปลงระหว่างช่วงเวลา

การแปลงค่ากลับ โดยใช้ EXP( ) ใน Excel

Quarter	Sales	Log (Sales)	Time
Q1-1999	61.14	4.11	1
Q2-1999	64.07	4.16	2
Q3-1999	66.18	4.19	3
Q4-1999	72.76	4.29	4
Q1-2000	**?**	**4.4572**	5

Log(Y) = 0.0654*t + 4.1302

Log(Y) = 0.0654*5 + 4.1302 = **4.4572**

Sales = EXP(0.0654*5+4.1302) = EXP(4.4572)

= 82.645

ตัวอย่างการ Forecast Exponential Trend

- PC Device Sales.xlsx
- โจทย์: ให้ทำพยากรณ์ทั้ง Linear และ Exponential Trends
  - 12) Data Set 12_12

Moving Averages

Moving Averages

➲ Moving Averages (MA) เป็นวิธีหนึ่งในการพยากรณ์ข้อมูลสำหรับ Time Series ที่ง่ายที่สุดและอาจจะถือว่าเป็นที่นิยมใช้กันมากที่สุดด้วย เราสามารถเขียนสูตรที่ใช้ในการพยากรณ์ในรูปสมการได้ดังนี้

$$F_t = \frac{1}{k}(Y_{t-1} + Y_{t-2} + \ldots + Y_{t-k})$$

Span (k) คือ จำนวนข้อมูลย้อนหลังที่เราจะนำมาใช้ในการหาค่าเฉลี่ย

F_t คือ ค่าของตัวแปรที่ต้องการพยากรณ์ที่เวลา t

$Y_{t-1}, Y_{t-2}, \ldots, Y_{t-k}$ คือ ค่าของตัวแปรย้อนหลังที่อยู่ใน Span ที่ต้องการใช้

Time Series

t	Data (Y)
1	4
2	3
3	5
4	7
5	6
6	5
7	

$$F_7 = (Y_6 + Y_5 + Y_4) / 3$$

$$= (5 + 6 + 7) / 3$$

$$= 6$$

Moving Averages

การเลือกขนาดของ Span มีความสำคัญอย่างมาก

* **ถ้าเลือก Span ที่มีช่วงกว้างมาก** จำนวนค่าของข้อมูลที่นำมาใช้ในการหาค่าเฉลี่ยมีมากขึ้น จึงทำให้ผลลัพธ์จากการพยากรณ์ได้ค่าที่ค่อนข้างจะ Smooth บางครั้งเราจึงเรียกวิธีนี้ว่า **Smoothing method**

* **ถ้าเลือก Span ที่มีช่วงน้อยลง** ค่าพยากรณ์มีความแตกต่างจากค่าของข้อมูลก่อนหน้าค่อนข้างมาก และถ้า Span เท่ากับ 1 ค่าจากการพยากรณ์จะเท่ากับค่าของข้อมูลก่อนหน้านี้หนึ่งช่วงเวลา เราจะเรียก MA กรณีแบบนี้ว่า **Naïve forecasting method**

Moving Averages

ข้อเสียของ Moving averages

❶ ให้น้ำหนัก (ความสำคัญ) ของข้อมูลที่ผ่านมา (ในอดีต) ที่อยู่ในช่วงเวลาต่างๆ เท่ากัน

❷ วิธี Moving averages จำเป็นต้องใช้มีการเก็บค่าของข้อมูลในอดีตไว้ ทำให้มีต้นทุนในการจัดเก็บข้อมูล (ไม่เป็นปัญหาสำหรับในปัจจุบันเนื่องจากระบบการเก็บข้อมูลมีต้นทุนต่ำมาก)

Time Series

t	Data (Y)
1	4
2	3
3	5
4	7
5	**6**
6	**5**
7	

Hold Out

Hold Out คือ การกันข้อมูลบางส่วนเอาไว้สำหรับใช้ในการทดสอบการพยากรณ์

$$F_5 = (Y_4+Y_3) / 2$$
$$= (5 + 7) / 2$$
$$= 6$$

$$F_6 = (Y_5+Y_4) / 2$$
$$= (6 + 7) / 2$$
$$= 6.5$$

Time Series

t	Data (Y)
1	4
2	3
3	5
4	7
5	**6**
6	**5**
7	

Error

$E_5 = 6 - 6 = 0$

$E_6 = 5 - 6.5 = -1.5$

MAE = [0 + |-1.5|] / 2

= 0.75

$F_7 = ?$

ตัวอย่าง Moving Averages

- House Sales.xlsx
- โจทย์: ให้ทำพยากรณ์โดยใช้ Moving Averages
  - 28) Data Set 12_10
  - 29) Data Set 12_29
  - 30) Data Set 02_28

Business Forecasting – Summary

- Forecasting : Motivation, Business examples
- Forecasting Methods: Judgmental, Time Series, Econometric
- Random Pattern Detection
- Forecasting Error
- Trend Model (Regression-based Methods)
- Moving Averages

Exponential Smoothing

Exponential Smoothing

- ถูกพัฒนาขึ้นมาเพื่อแก้ข้อวิจารณ์ของ MA คือ
  - ให้ความสำคัญกับข้อมูลในอดีตเท่ากันหมด
  - จำเป็นต้องเก็บข้อมูลในอดีตจำนวนมาก เช่น ถ้าใช้ MA ที่มี span เท่ากับ 12 เดือน สำหรับบริษัทที่มีสินค้า 1,000 SKU จำเป็นต้องเก็บข้อมูลจำนวน 12,000 ค่า
- ใช้ค่าเฉลี่ยถ่วงน้ำหนักของข้อมูลในอดีตและใช้เนื้อที่ในการเก็บข้อมูลจำนวนน้อยมาก

Exponential Smoothing

Exponential Smoothing มีหลายวิธี แต่วิธีที่เป็นที่นิยมและใช้อย่างแพร่หลายจะมี 3 วิธี คือ

* **Simple Exponential Smoothing** – เหมาะสำหรับข้อมูลที่ไม่มี Trend หรือ Seasonality ปรากฏอยู่อย่างชัดเจน

* **Holt's Method** – เหมาะสำหรับข้อมูลที่มี Trend ปรากฏอยู่แต่ไม่มี Seasonality

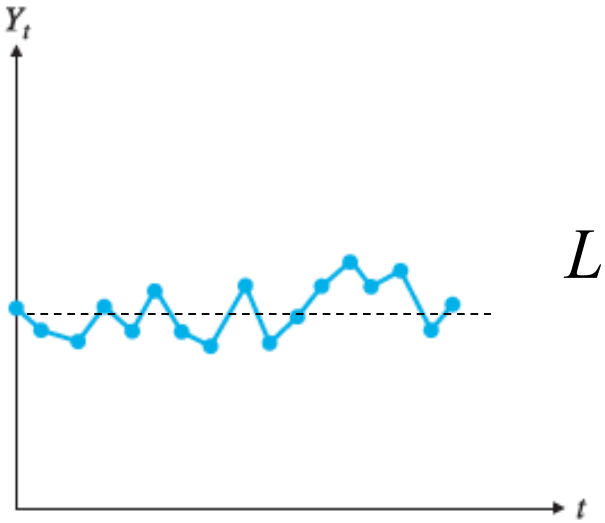
* **Winters' Method** – เหมาะสำหรับข้อมูลที่มี Seasonality ปรากฏอยู่ และ/หรืออาจจะมี Trend ร่วมอยู่ด้วย

Simple Exponential Smoothing

- **ค่าคงที่ Smoothing Constant** – ค่า α (อ่านว่า Alpha) โดยที่ค่า Alpha นี้จะมีค่าระหว่าง 0 กับ 1
  - เป็นค่าคงที่ที่จะใช้ในการถ่วงน้ำหนักของข้อมูลเพื่อใช้ในการพยากรณ์ (คล้ายๆ กับค่า Span ใน MA ที่เราต้องเลือก)

- **ค่าระดับ (Level) ของ Time Series** ที่เวลา t ซึ่งจะใช้สัญลักษณ์ L_t
  - เป็นค่าที่ประมาณการณ์ว่าระดับของ Time Series จะอยู่ที่ค่าไหนที่เวลา t ถ้าไม่มี Noise เกิดขึ้น

ค่าระดับ *(Level)* ของ *Time Series* ที่เวลา *t*



L_t เป็นการคาดการณ์ว่า Time Series จะอยู่ที่ระดับใด

Simple Exponential Smoothing

STEP 1

ค่าระดับที่เวลา t ค่าระดับที่เวลา t-1

$$L_t = \alpha Y_t + (1-\alpha)L_{t-1}$$

ข้อมูลที่สังเกตได้ที่เวลา t

ตัวอย่าง เช่น $\alpha = 0.7, Y_t = 3, L_{t-1} = 6$

เราสามารถหาค่า $L_t = 0.7 \times 3 + (1-0.7) \times 6$

$= 2.1 + 1.8 = 3.9$

Simple Exponential Smoothing

STEP 2

หาค่าระดับที่เวลา t ได้แล้ว เราจะทำการพยากรณ์ค่าของ Time Series ที่เวลาถัดๆ ไปได้โดยใช้หลักการว่าถ้า Time Series ไม่ได้มี Trend หรือ Seasonality ***ระดับของ Time Series จะอยู่ที่ค่าระดับที่เวลาสุดท้ายที่พยากรณ์ไว้***

$$F_{t+k} = L_t, \qquad k = 1, 2, 3, \ldots$$

ตัวอย่าง เช่น

$$F_{t+1} = L_t = 3.9, \; F_{t+2} = L_t = 3.9, \ldots$$

Simple Exponential Smoothing

Simple Exponential Smoothing สามารถนำมาใช้ในการพยากรณ์ได้ดังนี้

$$L_t = \alpha Y_t + (1-\alpha)L_{t-1}$$

$$F_{t+k} = L_t,\ k \geq 1$$

α คือ Smoothing Constant ซึ่งมีค่าอยู่ระหว่าง 0 ถึง 1

L_t คือ ค่าระดับ (Level) ของ Time Series ที่เวลา t

F_{t+k} คือ ค่าพยากรณ์ของ Y_{t+k}

Time Series

t	Data (Y_t)
1	4
2	3
3	5
4	7
5	6
6	5
7	

$$L_t = \alpha Y_t + (1-\alpha) L_{t-1}$$

ถ้ากำหนดให้ $\alpha = 0.2$

$$L_1 = 0.2 \times 4 + (1 - 0.2) \times L_0$$

$$L_0 = ?$$

Time Series

t	Data (Y)
1	4
2	3
3	5
4	7
5	6
6	5
7	

เราคำนวณ L_0 โดยใช้ค่าเฉลี่ยของข้อมูลจะได้

$$L_0 = \frac{4+3+5+7+6+5}{6} = 5$$

$$L_1 = 0.2 \times 4 + (1 - 0.2) \times L_0$$

$$L_1 = 0.8 + 0.8 \times 5 = 4.80$$

$$L_2 = 0.2 \times Y_2 + (1 - 0.2) \times L_1 = 0.2 \times 3 + 0.8 \times 4.8 = 4.44$$

Time Series

Simple Exponential Smoothing

$\alpha = 0.2$

$L_0 = 5$

t	Data (Y_t)	Level (L_t)
1	4	**4.80**
2	3	**4.44**
3	5	
4	7	
5	6	
6	5	
7		

Time Series

Simple Exponential Smoothing

$\alpha = 0.2$

$L_0 = 5$

t	Data (Y_t)	Forecast (F_{t+1})	Level (L_t)
1	4	4.80 (F_2)	4.80 (L_1)
2	3	4.44 (F_3)	4.44 (L_2)
3	5		
4	7		
5	6		
6	5	____ (F_7)	
7			

$F_{t+k} = L_t, k \geq 1$

$F_{t+1} = L_t$

Time Series

Simple Exponential Smoothing

$\alpha = 0.2$

$L_0 = 5$

t	Data (Y_t)	Forecast (F_{t+1})
1	4	-
2	3	4.80
3	5	4.44
4	7	
5	6	
6	5	
7		

คำนวณ MAE, RMSE, MAPE

Simple Exponential Smoothing

เราสามารถแปลความหมายของ SES ได้ 2 แบบ

1. การประมาณค่าระดับเกิดจากการใช้ Forecast Error มาปรับกับค่าที่เกิดขึ้นจริง

$$L_t = \alpha Y_t + (1-\alpha) L_{t-1}$$

$$L_t = L_{t-1} + \alpha (Y_t - L_{t-1})$$

Forecast error (E_t)

Simple Exponential Smoothing

❷ ค่า Y ที่ยิ่งห่างไกลจากค่าพยากรณ์ ยิ่งมีความสำคัญต่อการพยากรณ์น้อยลง เนื่องจาก α และ $(1-\alpha)$ ต่างมีค่าน้อยกว่า 1 ดังนั้น เมื่อ n มีค่าเพิ่มขึ้นเรื่อยๆ จะทำให้ $\alpha(1-\alpha)^n$ มีค่าลดลงเรื่อยๆ

$$L_t = \alpha Y_t + (1-\alpha)L_{t-1}$$



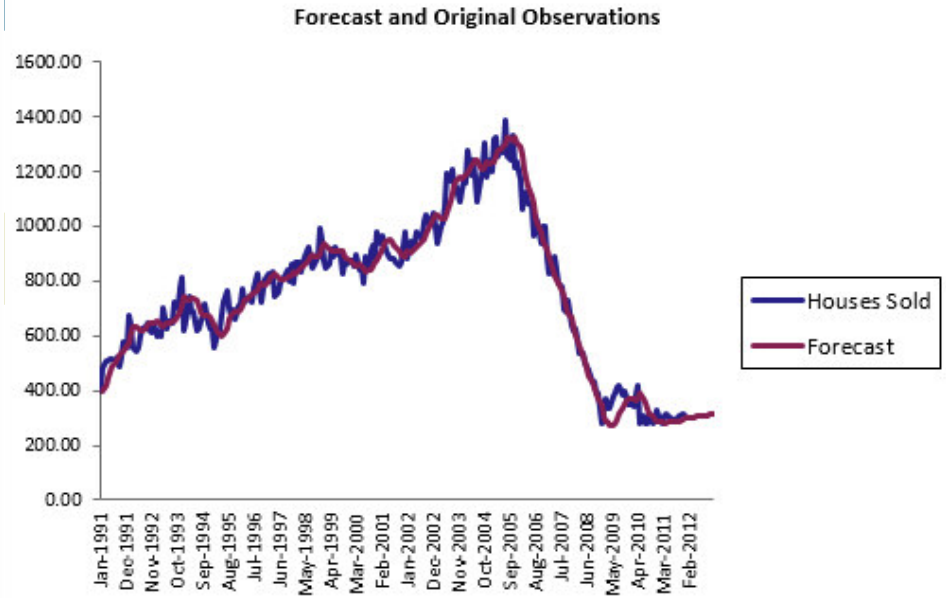
$$L_t = \alpha Y_t + \alpha(1-\alpha)Y_{t-1} + \alpha(1-\alpha)^2 Y_{t-2} + \alpha(1-\alpha)^3 Y_{t-3} + \ldots$$

Simple Exponential Smoothing

ปัญหาที่สำคัญ คือ เราควรจะใช้ค่า α เท่าไหร่ถึงจะเหมาะสม คำแนะนำมีดังนี้

- ควรใช้ค่าประมาณ 0.1 หรือ 0.2
- ควรใช้ค่าที่ทำให้ RMSE หรือ MAPE มีค่าน้อยที่สุด (โดยโปรแกรมทางสถิติสามารถคำนวณหาค่าให้ได้)

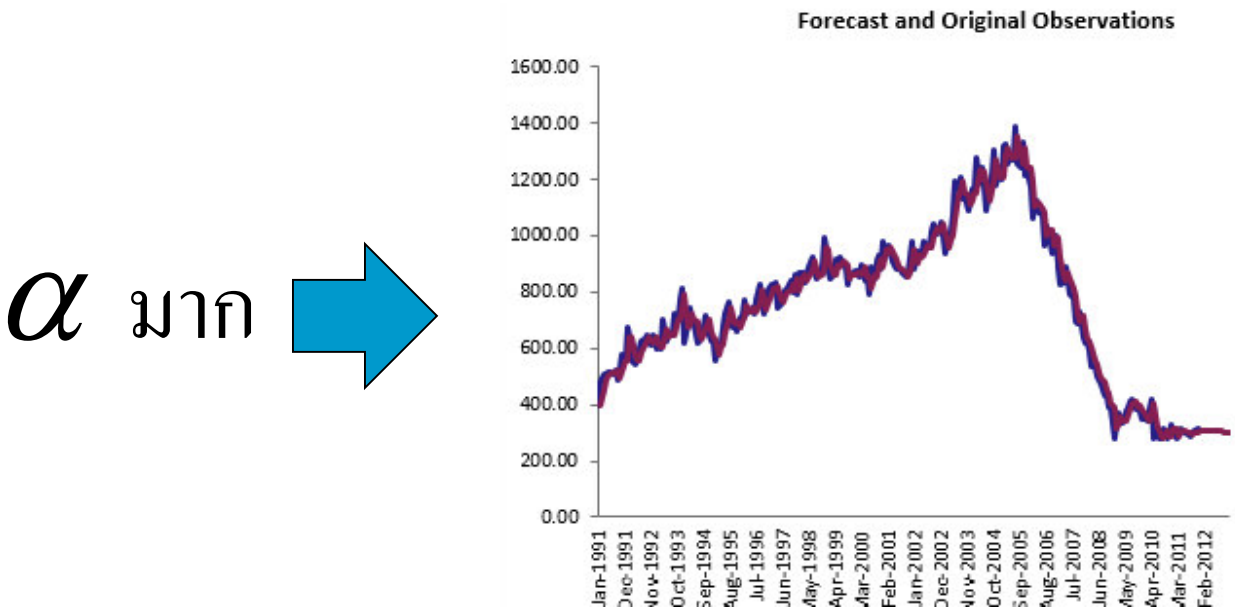
α ค่าน้อยทำให้เกิด Smoothing ส่วนค่ามาก ทำให้เกิดการ Track Time Series ได้ดี





α น้อย

α มาก



Simple Exponential Smoothing

แม้ว่าค่า α ที่ได้จะเป็นค่าที่เหมาะสมที่สุดจากการหาจากข้อมูลในอดีตแต่ก็ไม่ได้มีอะไรรับประกันได้ว่าค่านี้จะทำให้เราสามารถพยากรณ์ค่าที่กำลังจะเกิดขึ้นในอนาคตได้ถูกต้องที่สุด

ตัวอย่าง

- House Sale.xlsx

- โจทย์
  - 32) Data Set 12_01
  - 33) Data Set 12_04
  - 35) Data Set 02_44

Holt's Method

(Double Exponential Smoothing)

Holt's Method

Simple Exponential Smoothing ไม่สามารถใช้ในการพยากรณ์ Time Series ที่มี Trend ได้ดีเนื่องจากค่าจากพยากรณ์จะ Delay การแก้ปัญหาจึงจำเป็นต้องมีการประมาณการณ์หาค่า Trend ที่เกิดขึ้นและใช้ร่วมในการพยากรณ์

Holt's Method

ของเดิม Simple ES $L_t = \alpha Y_t + (1-\alpha)L_{t-1}$

$$L_t = \alpha Y_t + (1-\alpha)(L_{t-1} + T_{t-1})$$

$$T_t = \beta(L_t - L_{t-1}) + (1-\beta)T_{t-1}$$

Smoothing Constant สำหรับค่า Trend

Holt's Method

การพยากรณ์ใช้ Trend มาปรับเพิ่มจากค่าระดับในแต่ละช่วงเวลา

$$F_{t+k} = L_t + kT_t, \qquad k \geq 1$$

Holt's Method

การพยากรณ์สำหรับข้อมูลที่มี Trend เข้ามาเกี่ยวข้อง ทำได้ตามนี้

$$L_t = \alpha Y_t + (1-\alpha)(L_{t-1} + T_{t-1})$$

$$T_t = \beta(L_t - L_{t-1}) + (1-\beta)T_{t-1}$$

$$F_{t+k} = L_t + kT_t, \; k \geq 1$$

Holt's Method

β (Smoothing constant) จะเข้ามาช่วยในการควบคุมการเปลี่ยนแปลงของ Trend

* ถ้าค่า β มีค่า**น้อย** จะทำให้ Trend ที่ได้มีการเปลี่ยนแปลงค่อนข้างช้า

* ถ้าค่า β มีค่า**มาก** จะทำให้ Trend ที่ได้มีการเปลี่ยนแปลงอย่างรวดเร็ว

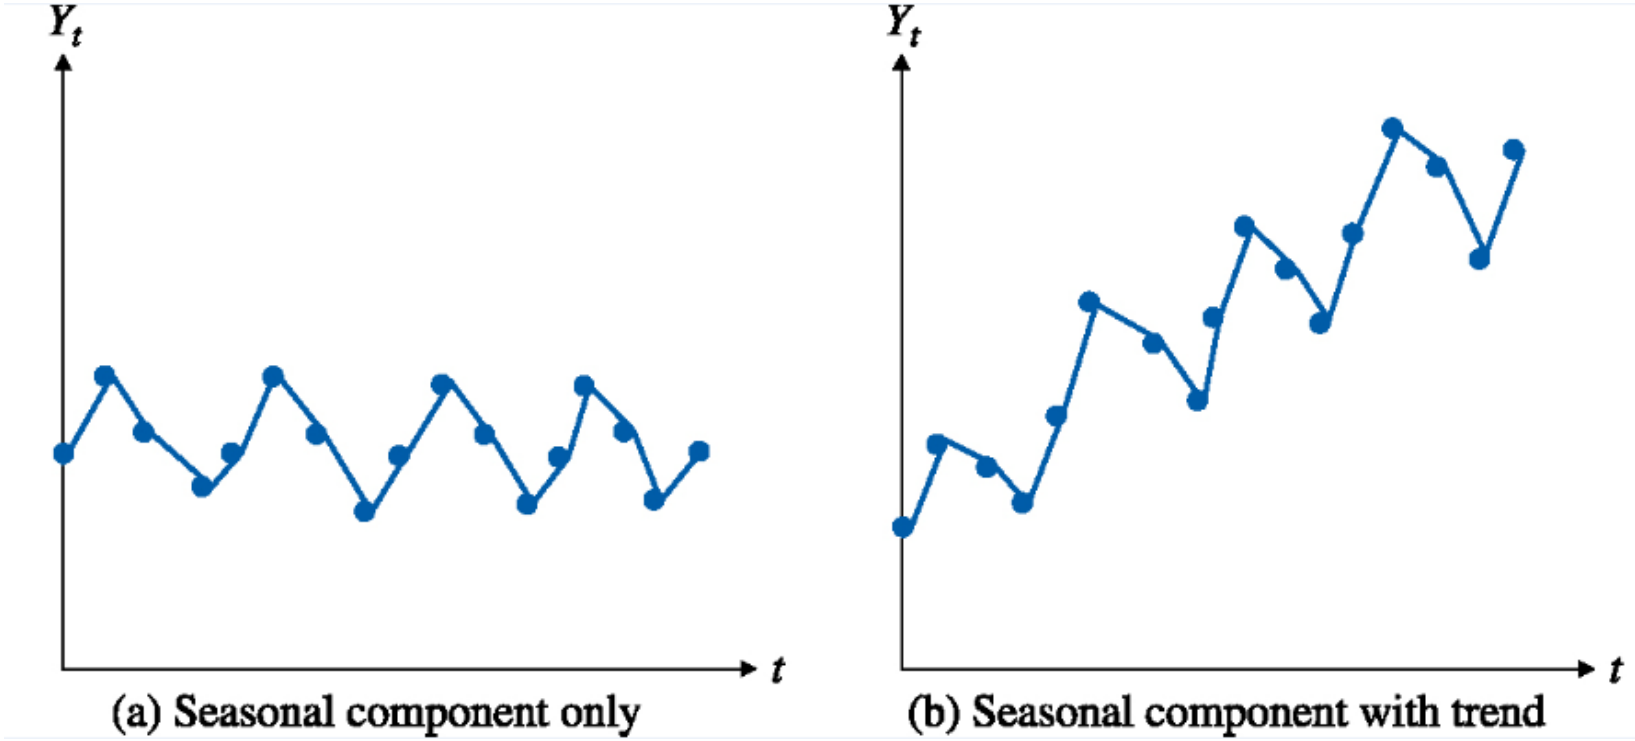
ค่าที่แนะนำอยู่ที่ประมาณ 0.2 หรือใกล้เคียงกับ α

ตัวอย่าง

- House Sale.xlsx (ต่อโดยใช้ Holt's Method)
- โจทย์
  - 32) Data Set 12_01
  - 34) Data Set 12_16
  - Soft Drink Sales.xlsx

Seasonal Data

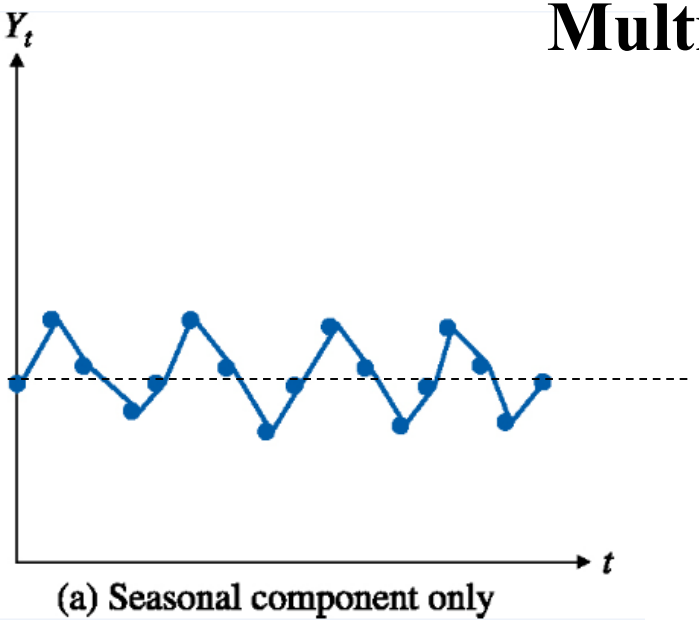
ฤดูกาล (Seasonality) – ค่าของตัวแปรมีรูปแบบที่ซ้ำกันเป็นรอบในช่วงเวลาที่เท่ากัน และมีรูปแบบที่ซ้ำกันแบบนี้ไปเรื่อยๆ



(a) Seasonal component only

(b) Seasonal component with trend

Multiplicative Seasonal Model



(a) Seasonal component only

ค่าเฉลี่ยทั้งหมดของข้อมูลอยู่ที่ระดับ 100

Seasonality Index ของไตรมาส 2 มีค่าเท่ากับ 1.4 ดังนั้น ยอดขายของไตรมาส 2 จะมีค่าเท่ากับ 140 หน่วย

Seasonality Index ของไตรมาส 4 มีค่าเท่ากับ 0.7 ดังนั้น ยอดขายของไตรมาส 4 จะมีค่าเท่ากับ _____ หน่วย

การพยากรณ์สำหรับ Seasonal Data

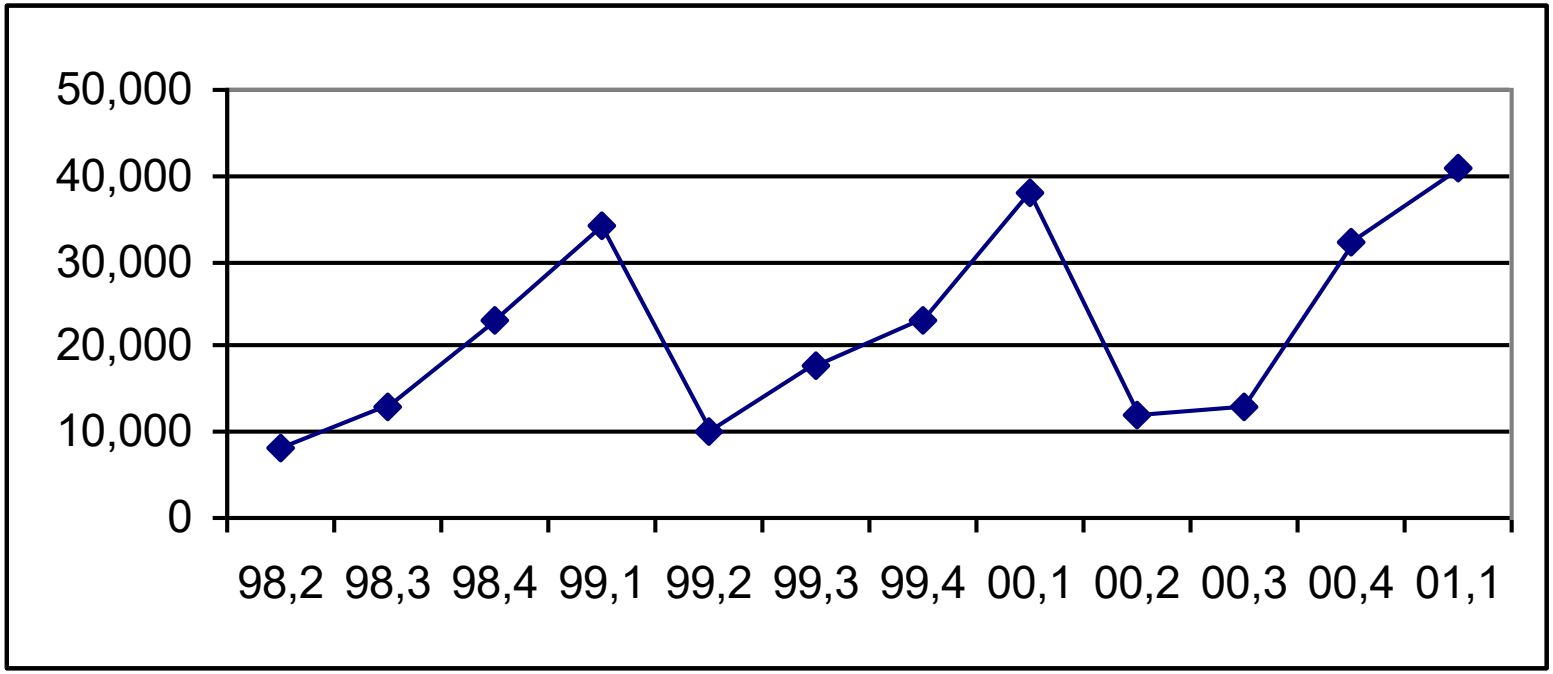
- การ Deseasonalize ข้อมูล
  - ถอด Seasonality ออกจากข้อมูล
  - Seasonality Index
- การพยากรณ์ข้อมูลที่ถูก Deseasonalized แล้ว
  - ใช้วิธีการที่ทำมาแล้ว
- การใช้ Seasonality Index สำหรับการปรับค่าตามฤดูกาล

Ratio-to-Moving-Average Method

ตัวอย่าง Toy Sales

Quarter	Demand D_t
II, 1998	8000
III, 1998	13000
IV, 1998	23000
I, 1999	34000
II, 1999	10000
III, 1999	18000
IV, 1999	23000
I, 2000	38000
II, 2000	12000
III, 2000	13000
IV, 2000	32000
I, 2001	41000

History for Toy Sales



ตัวอย่าง Toy Sales

Quarter	Demand D_t
II, 1998	8000
III, 1998	13000
IV, 1998	23000
I, 1999	34000
II, 1999	10000
III, 1999	18000
IV, 1999	23000
I, 2000	38000
II, 2000	12000
III, 2000	13000
IV, 2000	32000
I, 2001	41000

(8,000+13,000+23,000+34,000) / 4

= 19,500

ค่าเฉลี่ยอยู่ระหว่าง Q2 กับ Q3

ตัวอย่าง Toy Sales

Quarter	Demand D_t
II, 1998	8000
III, 1998	13000
IV, 1998	23000
I, 1999	34000
II, 1999	10000
III, 1999	18000
IV, 1999	23000
I, 2000	38000
II, 2000	12000
III, 2000	13000
IV, 2000	32000
I, 2001	41000

(13,000+23,000+34,000+10,000) / 4

= 20,000

ค่าเฉลี่ยอยู่ระหว่าง Q4 กับ Q1

ตัวอย่าง Toy Sales

Quarter	Demand D_t
II, 1998	8000
III, 1998	13000
IV, 1998	23000
I, 1999	34000
II, 1999	10000
III, 1999	18000
IV, 1999	23000
I, 2000	38000
II, 2000	12000
III, 2000	13000
IV, 2000	32000
I, 2001	41000

ค่าเฉลี่ยของ Q4

(19,500 + 20,000) / 2

= 19,750

Seasonalized Data ของ Q4 จากข้อมูล 6 ค่าแรกมีค่าเท่ากับ 19,750

Seasonality Index ของ Q4 จากข้อมูล 6 ค่าแรกมีค่าเท่ากับ 23,000/19,750 = 1.16

ตัวอย่าง Toy Sales

Quarter	Demand D_t	Deseasonalized	Seasonality Index
II, 1998	8000	-	-
III, 1998	13000	-	-
IV, 1998	23000	19,750	1.16
I, 1999	34000		
II, 1999	10000		
III, 1999	18000		
IV, 1999	23000		
I, 2000	38000		
II, 2000	12000		
III, 2000	13000		
IV, 2000	32000		
I, 2001	41000		

ตัวอย่าง Toy Sales

Period t	Demand Dt	Deseasonalized
1	8000	
2	13000	
3	23000	19750
4	34000	20625
5	10000	21250
6	18000	21750
7	23000	22500
8	38000	22125
9	12000	22625
10	13000	24125
11	32000	
12	41000	

$$\textit{Linear Trend: } D_t = 18438 + 524t,$$

Seasonal Index

Period t	Demand Dt	Deseasonalized	Seasonal factor
1	8000	18962	0.42
2	13000	19486	0.67
3	23000	20010	1.15
4	34000	20534	1.66
5	10000	21058	0.47
6	18000	21582	0.83
7	23000	22106	1.04
8	38000	22630	1.68
9	12000	23154	0.52
10	13000	23678	0.55
11	32000	24202	1.32
12	41000	24726	1.66

$$\bar{D}_t = 18438 + 524t \qquad \bar{S}_t = D_t / \bar{D}_t$$

Seasonal Index

$$S_1 = (0.42+0.47+0.52)/3 = 0.47$$
$$S_2 = (0.67+0.83+0.55)/3 = 0.68$$
$$S_3 = (1.15+1.04+1.32)/3 = 1.17$$
$$S_4 = (1.66+1.68+1.66)/3 = 1.67$$

Forecasting

$$F_{13} = (L+13T)S_1 = [18438+13x524]x0.47 = 11868$$

$$F_{14} = (L+14T)S_2 = [18438+14x524]x0.68 = 17526$$

$$F_{15} = (L+15T)S_3 = [18438+15x524]x1.17 = 30769$$

$$F_{16} = (L+16T)S_4 = [18438+16x524]x1.67 = 44793$$

ตัวอย่าง

- Soft Drink Sales.xlsx

- โจทย์
  - 44) Data Set 02_55
  - 49) Data Set 12_49
  - 51) Data Set 12_51

Winters' Method

(Triple Exponential Smoothing)

Winters' Method

Winters' Method จะมีลักษณะคล้ายกับของ Holt's Method ที่มีค่าคงที่ α และ β ที่ใช้สำหรับประมาณค่าระดับ (Level) และค่าแนวโน้ม (Trend)

Winters' Method จะมีค่าคงที่เพิ่มมาอีกค่าหนึ่ง คือ γ เพื่อใช้อธิบายและควบคุมการเปลี่ยนแปลงของ Seasonality

Winters' Method

$$L_t = \alpha \frac{Y_t}{S_{t-M}} + (1-\alpha)(L_{t-1} + T_{t-1})$$

$$T_t = \beta(L_t - L_{t-1}) + (1-\beta)T_{t-1}$$

$$S_t = \gamma \frac{Y_t}{L_t} + (1-\gamma)S_{t-M}$$

$$F_{t+k} = (L_t + kT_t)S_{t+k-M}, \; k \geq 1$$

S_t คือ ดัชนีตัวคูณของฤดูกาล (Multiplicative Seasonal Index)

M คือ คาบของฤดูกาล (Periodicity) ของ Season

Winters' Method

ค่าของ γ ควรจะมีค่ามากกว่า α และ β

- ควรใช้ค่าประมาณ 0.4 – 0.5

ตัวอย่าง

- Soft Drink Sales.xlsx
- โจทย์
  - 44) Data Set 02_55
  - 49) Data Set 12_49
  - 51) Data Set 12_51

Business Forecasting – Summary

- Exponential Smoothing
- Holt's Method
- Seasonal Data
- Winters' Method

การรวมค่า *Forecast*

การรวมค่า Forecast

$$F_t = 0.5 \times F_t^1 + 0.5 \times F_t^2$$

วิธีการ Forecast แบบที่ 1

วิธีการ Forecast แบบที่ 2

การรวมค่า Forecast

$$F_t = w_1 \times F_t^1 + w_2 \times F_t^2$$

น้ำหนักสำหรับวิธี 1

น้ำหนักสำหรับวิธี 2

ตัวอย่าง

- P12_12.xlsx
- P02_28.xlsx

Random Walk

Random Walk Model

- แบบจำลองที่ถูกพัฒนาขึ้นมาเพื่อใช้สำหรับการจำลองราคาหุ้น
- Time Series ที่เป็น Random Walk จะมีผลต่างของราคาระหว่างช่วงเวลาที่ติดกันเป็น Random หรือ Noise
- เช่น Y_t เป็นราคาที่เวลา t ดังนั้น ผลต่างของ $Y_t - Y_{t-1}$ เป็น Random

Random Walk Model

$$Y_t - Y_{t-1} = \mathrm{m} + e_t$$

ค่า Drift

Random / Noise

หาได้จากค่าเฉลี่ยของ
ผลต่างราคา

การพยากรณ์

$$Y_{t+1} = Y_t + \mathrm{m}$$

95% Confidence Interval

Lower Limit : $Y_t + \mathrm{m} - 2 \times Standard\ Error$

Upper Limit : $Y_t + \mathrm{m} + 2 \times Standard\ Error$



หาจาก Standard Deviation ของผลต่างของราคา

ตัวอย่าง Random Walk Model

- Stock Price.xlsx
- โจทย์
  - P12_17.xlsx
  - P12_18.xlsx

Golden Rule of Forecast - กฎทองคำของการพยากรณ์

- **Forecast is always wrong.**
  (การพยากรณ์จะผิดเสมอ)

- **The longer the forecast horizon is, the worse is the forecast.**
  (ยิ่งพยากรณ์ไปในอนาคตไกลมากเท่าไหร่ ค่าที่พยากรณ์ก็จะแย่มากขึ้นเท่านั้น)

- **Aggregate forecast information is more accurate than disaggregate information.**
  (การพยากรณ์ค่าที่เป็นผลจากการรวมกันจะมีความแม่นยำมากกว่าการพยากรณ์แต่ละค่าแยกกัน)